Reminder 学习 04 / 198个中文账号清单：筛选方法与证据边界

把信息流变成实验
筛选规则 ≠ 质量真理

原始X Article全文 × 官方字段字典 × 真实文本计数与合成数值实验

198个唯一handle已核对，198份账号指标未验证

> 实读原帖全文与一手文档，完成6步离线实验、12项自写测试。不自动关注/退订，不创建列表，不批量采集真人指标；合成数据的通过率不代表真人通过率。

可以用在哪儿?

- 为一个主题挑选少量候选信源，先试读，再决定是否纳入阅读列表。
- 将模糊“活跃/有互动”翻译成可测试的门槛与缺失值规则。
- 核查榜单人数、去重和流转账，而非照单全收。
- 识别爆款均值、粉丝规模与快照过期对筛选结果的影响。

查重与增量

已读固定main的00-总览、信息素养、证据优先质检。旧库已有“查官网原文/口径标签”；本项只追加筛选公式、三态缺失、198名单结构审计与140标记≠138人数的反例，不重复泛化信息素养定义。

从名单读法，到透明筛选

01 198是当前仍有效的推荐保证吗?

不是。原文给出2026-10-19/20的数据采集批次，并说明粉丝与互动会变。本轮只获得文章全文，没有643候选或198人的逐条原始指标。可以核验文本与计算方法，不能把作者“全部筛过”改写为我们的当前账号认证。[S1]

作者历史快照 → 本轮实读正文 → 当前指标未核验

02 Top30加完整名单会重复算吗?

按章节界限提取@handle，再按小写去重：Top30为30，后续完整名单为168，交集为空，总计198个唯一handle。这验证账号字符串不重复；一人多号、改名和现实身份是否重复，仍不能仅靠handle去重证明。[S1]

30 + 168 → 198唯一handle → 真人身份未去重

03 新增人数该数哪个单位?

正文称138个新面孔。第一次直接数🆕得到140，因为包含两处说明图例；改数带@handle且有🆕的名单行，得到138。保留初次输出和修订重跑。由198−138可算旧名单最终留存60，但不能把60与“94位当前达标”混为同一阶段。[S1]

字面标记140 → 排除两处图例 → 名单行138

从名单读法，到透明筛选

04 流转数字能闭合吗？

旧名单94达标+7待看+45掉队=146；掉队原因14+11+8+3+3+3+3=45。新名单180+42−4−20=198；领域30+94+28+20+20+6=198。闭合只是内部一致性，不证明643→424→360→180每一步采样无偏，也不验证人工筛选理由。[S1]

旧名单146 → 新增/删减闭合 → 不等于数据真实

05 互动条件到底怎样写成代码？

设粉丝F、中位浏览V、中位点赞L：V≥max(300,0.01F)，或L≥max(5,0.0002F)。每个分支内部是“且”，两个分支间是“或”。例如F=10万时门槛是浏览1000或点赞20；合成样本999浏览、20点赞可以从点赞分支通过。[S1]

分支内AND → 两分支OR → 规模相对门槛

06 活跃、原创和中文如何取口径？

原文要求粉丝≥5000、14天内有帖、30天原创≥8且中文为主。练习采用中文比例严格>0.5；边界“一半以上”的解释应明示。原文排除转推/回复，但未充分界定引用帖，真实复现前必须补口径。本练习输入已汇总字段，不伪装成抓取后的原创分类。[S1][S2]

时间窗口固定 → 原创分类要定义 → 中文阈值明示

从名单读法，到透明筛选

07 为什么中位数比平均数稳一些？

Python官方median按排序中间值，偶数取中间两项平均。本轮合成浏览[100×7,10000]：均值1337.5，中位数100。用300门槛时均值会过、中位数不过；这展示单个爆款的影响，不表示中位数能识别买量、事实准确性或专业质量。[S3]

7条100+1条10000 → 均值1337.5 → 中位数100

08 读不到指标就按零处理吗？

不应。练习为pass/reject/unknown三态：已知硬门槛失败就拒绝；未失败但关键指标缺失就未知；浏览分支已过时，缺点赞仍可通过。NaN和布尔值不当有效数字。官方字典描述public_metrics和followers_count等字段，但字段存在不代表任意账号可免费完整获取。[S2]

缺失不是零 → OR允许单路证据 → 证据不足为unknown

09 推广排除与人工例外会冲突吗？

原文排除返佣、付费群及推广等，并公开说明哥飞有自家产品链接仍破例收录。这说明列表不只是阈值计算，还含作者编辑判断。应把例外、理由、日期单列，不暗改规则。本轮只用虚构promotion=True测试排除，不对原文真人作新负面判断。[S1]

数值初筛 → 人工规则/例外 → 保留理由与日期

从名单读法，到透明筛选

10 约450条能当精确科学边界吗?

不能。原文说近30天原创“约450条以上”像批量发帖，是经验警戒线。练习为可执行性选定>450拒绝，并明确这是本地离散化，不冒称作者精确实现。另将浏览底线299/300/301扫过，边界样本结果pass/pass/reject，揭示阈值敏感性。

作者经验约450 → 练习明确>450 → 敏感不等于质量差

11 半年重筛是规律还是经验?

只是作者对旧名单复盘的经验表述，不是统计验证的有效期。本轮合成账号以“7天前最后发帖”起算，经过0/7/8/180天后年龄7/14/15/187天，规则结果过/过/拒/拒。真实账号仍可能继续发帖，所以这只是冻结输入老化实验；没有创建定期任务。

冻结快照 → 时间会推移 → 真人行为未预测

12 怎样真正落地而不被榜单反向支配?

选单主题与少量候选，保留文章快照、指标日期、缺失项和人工例外；再用连续试读检验对自己任务是否有帮助。量化门槛衡量规模/活跃/互动，不等于真实性、专业性或投资适用性。本轮只提供候选知识和离线代码，不替用户关注、投资、订阅或发布。

小范围试读 → 记录来源与反例 → 人决定纳入/移除

主实验：真实文本审计＋合成筛选敏感性

Python3.13标准库，完全零密钥/零API。第2步是真实文章计数，第3—5步用明确合成数据。

1. 固定公开证据

目的与操作：为原帖、正文、X字段文档、Python文档记录SHA256。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py manifest
```

真实结果：4份文件字节与SHA256已写results/manifest.json。

验证：重算哈希；访问日期与版本见sources.md。

2. 章节提取与流转审计

目的与操作：按章节提取账号；大小写去重；核对标记人数。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py audit
```

真实结果：30+168=198，唯一198，交集0；140字面标记但138名单行。

验证：results/article-audit.json与原文逐节对照；不等于身份去重。

3. 三态筛选实跑

目的与操作：以8个虚构样本验证AND/OR、比例门槛与缺失。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py filtering
```

真实结果：2通过、5拒绝、1未知；不对应任何真人账号。

验证：results/filtering.json包含全部输入/原因。

主实验：真实文本审计＋合成筛选敏感性

Python3.13标准库，完全零密钥/零API。第2步是真实文章计数，第3—5步用明确合成数据。

4. 均值与阈值敏感性

目的与操作：以八个合成浏览值对比median/mean并扫阈值。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py sensitivity
```

真实结果：均值1337.5、中位数100；299/300/301门槛→过/过/拒。

验证：results/sensitivity.json；阈值局部变化不证明质量变化。

5. 冻结快照老化

目的与操作：只推进合成时间，不模拟真人新发帖。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py aging
```

真实结果：帖子年龄7/14/15/187天→过/过/拒/拒；创建任务0。

验证：results/aging.json；半年是作者经验，未验证预测规律。

6. 边界语义复验

目的与操作：12项自写unittest覆盖OR/缺失/NaN/半数/时间。

```
cd /workspace/reminder-batch/worker-689b81da/item04
python3 exercise/source_filter_lab.py test
```

真实结果：Ran 12 tests，OK，exit=0。

验证：output-step6.txt；不是上游套件或全榜单验证。

一手来源与证据边界

[S1] 作者原帖及Article全文；本地source-post.json/article.txt
https://x.com/AI_Jasonyu/status/2112564298429927449

[S2] X官方数据字典：Post/User字段与public_metrics
https://docs.x.com/x-api/fundamentals/data-dictionary

[S3] Python3.13官方statistics：median定义与限制
https://docs.python.org/3.13/library/statistics.html#statistics.median

```
访问：2026-11-11（Asia/Shanghai）
vault main：a8674777e18302b8804b137212b1396cbfe5a747
文章/文档非Git仓库，无Git SHA；内容SHA256见results/manifest.json。
运行时：Python3.13.5；无第三方依赖。
```

原帖发布2026-10-20 23:19:12（Asia/Shanghai），不是摘要收藏时间。作者称10-19/20采集；我们没有原始指标行。官方文档WebFetch遇403后，以同一公开URL正常HTTP读取成功；未读取密钥。12单测为自写，正文计数为实测，筛选与老化结果仅是合成数值实验。

HTML仅内联CSS与12个SVG，无嵌入字体、无大图。PDF为真实A4打印；逐页转图及作者排版检查另记pdf-check.md。