## 01 / 先辨真伪，再动手

LEARN / CLOUD LAB / 待验证

# GCP 预算熔断：90%不是费用硬上限

公开来源核验 × 10 个递进问题 × 一个主实验

**官方已公告订阅直用 CLI；切项目不是必经路。90%延迟告警无法保证零超额。**

### 实读结论

• 原帖把AI Pro切到GCP按量模式作为路径；Google 10月13日公告已明确 Pro/Ultra 在桌面与 CLI 直接获 Argon。因此“只能在 Gemini App”不能作为当前普遍结论。[S1/S4]

• 插件真实存在，固定SHA 980cc7336efbc3415fd8c99c5f299b132ab11e32。README自称 official standard，不等于Google官方背书；本次不安装或运行部署器。[S2]

• 上游函数通过 CloudBillingClient 解绑账单；本次保留函数原逻辑，只替换 SDK 为内存桩，合成测试真实执行。

• 官方说明预算通知至少一次、可能乱序，第一条可能延迟数小时；10%缓冲可被高消耗率轻易穿透。[S3]

### 查重与增量边界

已读MOC、付费调用回执与预算熔断、Metrik相关总览条目。已有“告警不等于硬停”不另起概念；本次新增上游函数类型转换反例、延迟预算公式与订阅/项目通道纠偏。

main a8674777e18302b8804b137212b1396cbfe5a747；读取 2026-11-11 01:07:46 CST（UTC+8）。严格区分：原帖自述／官方材料／本次实测／待验证。

### 阅读路径

第 2–6 页：由浅入深十问（每问独立 SVG）
第 7 页：用途与实验前半段
第 8 页：实验后半段、来源与未验证项

## 02 / 疑问即目录

### 01 订阅模式与项目模式是同一额度吗?

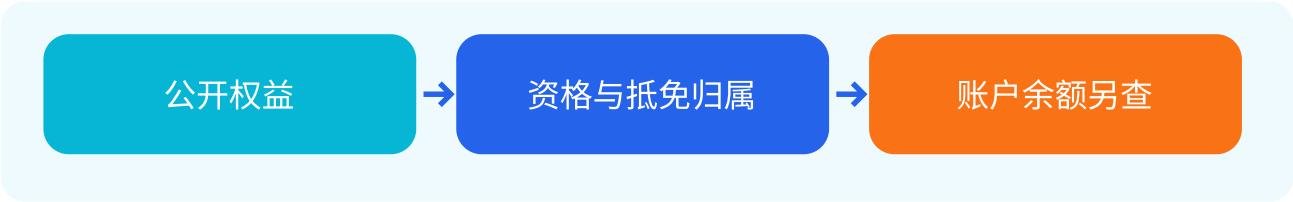
不是。订阅提供产品访问与使用限制；项目模式按云资源账单计量并可能用促销抵免抵扣。官方当前公告Pro/Ultra订阅也可直接在CLI用Argon，不能把注销订阅/切项目写成唯一办法。




依据：[S1], [S4], [S5]

### 02 每月10美元能否保证我的账户有钱?

官方价目确实列AI Pro每月10美元开发者云抵免，但用户能否领取、有效期、适用产品、剩余额度和账单账户归属还需本人账号核验。本次只核对公开权益，不读账号。




依据：[S5]

## 03 / 疑问即目录

### 03 插件是Google官方的吗?

仓库由AndyAWD发布，自称official standard plugin；这最多是README的自我描述。没有在本次Google官方材料中找到对该仓库的官方背书，故按第三方MIT插件对待。




依据：[S2], [S4]

### 04 告警链条中的每一层做什么?

预算统计生成消息，Pub/Sub投递，Cloud Run函数检查阈值并调用Cloud Billing API解绑。任何一层的延迟、权限缺失、重试或停机都能影响结果；收到告警不是已经停费。




依据：[S2], [S3]

## 04 / 疑问即目录

### 05 90%为什么不是零风险?

设预算B、阈值0.9、每小时消耗r、总延迟L；动作时费用约0.9B+rL。只有rL≤0.1B才可能不穿透缓冲，且仍不包括其他未计量费用。本例B=10、r=2、L=1得11。




依据：[S2], [S3]

### 06 毛费用和净费用为什么要分开?

抵免后净费用可暂时很小，但毛费用仍在增加。插件文档使用exclude-all-credits看抵免前费用；不能把净费用0视为没消耗，也不能不核对币种与统计窗口就套10美元。

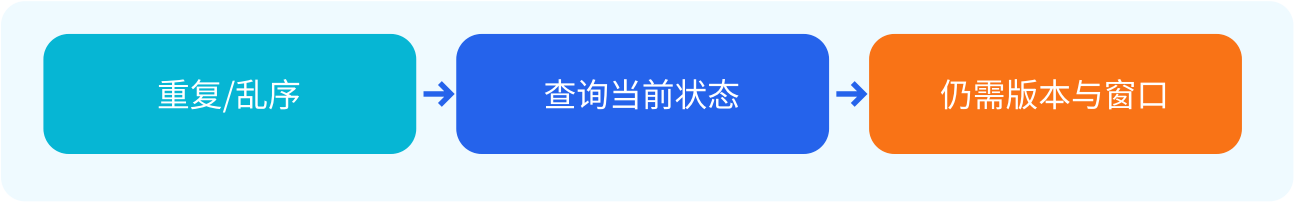



依据：[S2], [S3]

## 05 / 疑问即目录

### 07 消息重发与乱序怎样影响控制?

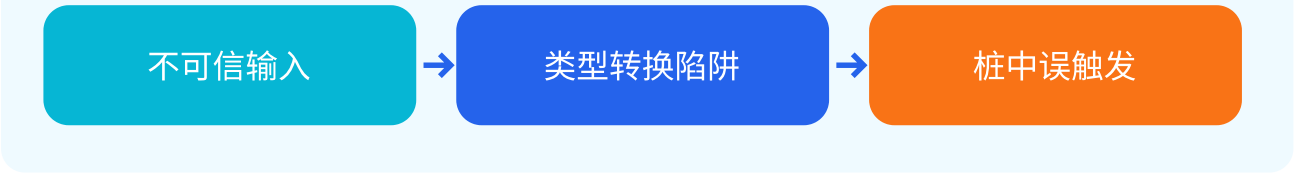
官方明确至少一次投递且可能乱序。上游先查询billingEnabled、关闭时不重复解绑，适合顺序重复消息；这不是跨实例原子幂等，也没证明重新启用后旧消息不会再次触发。




依据：[S2], [S3]

### 08 上游函数有什么可测的类型边界?

costAmount=abc转成NaN后比较均为false，可落到解绑分支；forceKill字符串false经Boolean转换为true也可触发。本次在隔离桩中实际观察到两者，说明需要schema校验，不是云安全漏洞已全面评估。




依据：[S2]

## 09 dryRun能证明生产权限与停费吗?

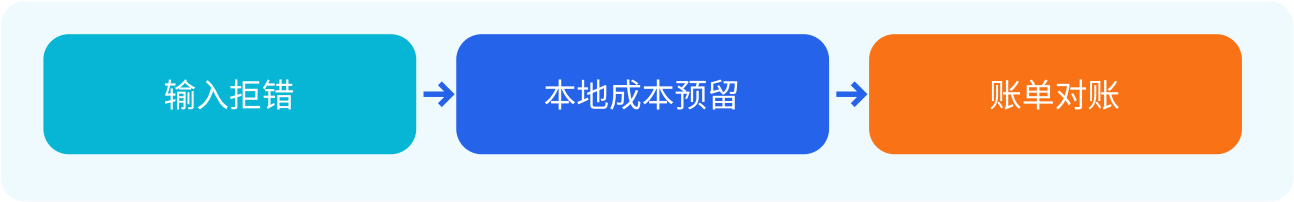
上游dryRun只读取getProjectBillingInfo，不执行update。即使真实读权限成功也不证明写权限与账单停用及时；本次甚至连真实读取都没有，只有内存桩调用计数。




依据：[S2]

## 10 怎样验收一个更安全的设计?

建议固定目标项目、校验有限数值和布尔类型、绑定币种/窗口、拒绝过期与非预期消息，并在请求发出前本地预留成本。真实账单仍是最终依据；本次8项特征化通过不代表系统安全。




依据：[S2], [S3]

# 07 / 能力与主实验

## 可以用来做什么（非产品效果承诺）

- 在不碰真实账单的情况下审查自动熔断函数分支。
- 计算并发消耗率与告警延迟所需缓冲。
- 避免把订阅、云抵免、Token统计混成一个余额。
- 写部署前审核清单，明确IAM/解绑属于另行授权动作。

### 步骤 1 · 固定8种预算消息

目的：创建正常、临界、dryRun和畸形字段场景

```
cd /workspace/reminder-batch-2026-11-11/item-3-billing-guard
node exercise/mock.mjs fixture
```

真实结果：cases.json含8种合成载荷

**验证：**没有用户项目ID、SDK凭据和网络调用

### 步骤 2 · 真实函数接入内存桩

目的：只替换SDK与export入口后执行固定版本函数

```
cd /workspace/reminder-batch-2026-11-11/item-3-billing-guard
node exercise/mock.mjs run
```

真实结果：8条结果保存get/update桩调用数；bad-number及字符串forceKill出现update

**验证：**below/dry/已关闭没有update；异常场景结果不掩盖

# 08 / 验证、来源与诚实边界

### 步骤 3 · 特征化断言

目的：按实际源码语义检查8个场景，包含不安全反例

```
cd /workspace/reminder-batch-2026-11-11/item-3-billing-guard
node exercise/mock.mjs verify
```

真实结果：8条当前行为检查通过，不是安全验收通过

**验证：**错误字段触发桩解绑必须被报告为发现

### 步骤 4 · 扫描延迟穿透

目的：计算0/0.5/1/24小时延迟下的合成总费用

```
cd /workspace/reminder-batch-2026-11-11/item-3-billing-guard
node exercise/mock.mjs delay
```

真实结果：1小时延迟总费用11、超预算1；真实云调用0

**验证：**B=10,r=2,阈值0.9；原始数值见日志

**待验证：**未登录GCP、未查用户抵免/订阅、未部署Pub/Sub/Cloud Run/IAM、未解绑或恢复结算、未调用任何收费模型；真实延迟、失效恢复与超额金额待验证。

## 可核查一手来源


S1 https://x.com/leo_xiaolei/status/2110563407502209342 — 原帖 article全文已读

S2 https://github.com/AndyAWD/antigravity-agent-platform/blob/980cc7336efbc3415fd8c99c5f299b132ab11e32/cloud-function/index.js — 固定SHA 函数第14–120行；README及billing-guard一并实读

S3 https://docs.cloud.google.com/billing/docs/how-to/notify — 官方通知格式与延迟/至少一次/乱序

S4 https://antigravity.google/blog/gemini-4-argon-in-google-antigravity/ — Google官方2026-10-13公告，订阅直接支持CLI

S5 https://developers.google.com/program/plans-and-pricing — 官方当前列AI Pro每月$10；不是用户账号余额


完整真实输出见 experiment-log.md；所有练习代码见 exercise.zip。未把作者宣称的性能、收入或成本当成本次测量。没有第三方独立审核。