硬件与Agent · 增量学习 07/07

Ivy AI：让大工作集轮流用内存

真实上游C arena主机测试，与板上离线语音严格分开

待验证

原帖已读，但所引用帖子实际讲Groki而非Ivy，已记录错链；通过项目官网和仓库核实Ivy。上游arena主机测试真实通过；未执行模型或ESP32语音。

先记住

不是。本批读到2112109068584473072谈Ivy，所引2111853756245737775却谈Groki Bot，并继续引用电池/Wi-Fi帖子。不能把该链当Ivy证据；另从Ivy官网与iamankushpandit/esp_ai一手仓库核实。

原帖：https://x.com/i/status/2112109068584473072
访问：2026-11-11（Asia/Shanghai）
知识库main：a8674777e18302b8804b137212b1396cbfe5a747

本册10个递进问题、10幅内联SVG、4个用途、4步可复跑实验。数字分清：作者报告 / 本批真实执行 / 教学合成 / 尚待验证。

Q01 原帖引用一定是Ivy的来源吗?

不是。本批读到2112109068584473072谈Ivy，所引2111853756245737775却谈Groki Bot，并继续引用电池/Wi-Fi帖子。不能把该链当Ivy证据；另从Ivy官网与iamankushpandit/esp_ai一手仓库核实。



Q02 Ivy与普通小智语音有什么区别?

Ivy README说听写、TinyTalk推理和SVOX Pico发声都在FNK0104B上，Wi-Fi用于NTP；普通小智通常把推理放后端。此为作者架构说明，本批无板子，未观测网络流量或离线声学链路。



Q03 8MB为什么装不下同时运行?

README估计STT约5.4MB、LLM约6.5MB，相加11.9MB已超过8MB，还没加TTS和系统常驻。自写近似账本把TTS2.5MB也计入得到14.4MB；这些是十进制教学算术，不是实测内存。



Q04 轮流使用怎样改变峰值?

若生命周期不重叠，共用大块arena，理想阶段峰值由求和变为取最大值6.5MB，7MB示例arena余0.5MB。实际还要计算常驻对象、对齐、内部SRAM、DMA与驱动，不能只凭这个不等式保证启动。



Q05 为什么要在开机时预留连续块?

MEMORY_BUDGET.md解释驱动先分配可能把内部内存切碎，剩余总量够却找不到大块。提前保留arena能稳定最大连续区域，但不是所有库都使用它；WakeNet等库仍有自己的堆分配。

开机大块 → 后续碎片 → 阶段复用

Q06 分配器如何阻止两个阶段同时占用?

真实story_arena_begin检查owner，已有owner则返回false；end清空owner和used。上游test_arena先取得stt，再尝试llm，预期拒绝；本机编译运行成功，但它是单线程所有权测试，不是多核互斥证明。

owner为空 → stt占用 → llm被拒

Q07 对齐、容量和回退测试分别查什么？

alloc按align计算补齐字节并核对剩余容量；mark/rewind回到局部水位。上游测试覆盖16字节对齐、超容量返回NULL及结束后整块复用。测试输入不能穷尽所有align或竞态，PASS不是分配器安全认证。

对齐补位 → 容量检查 → 水位回退

Q08 为什么首次编译失败不藏起来？

Linux gcc最初找不到esp_log.h；加入上游host/stubs官方日志桩include后编译成功，仍保留unused警告与初次失败。桩只替代日志适配，不替代arena分配算法；真实通过输出是test_arena OK。

缺日志适配 → 补官方桩 → 原件测试通过

Q09 固定SHA后文档就一定一致吗?

不一定。当前README说内部arena约145KB，MEMORY_BUDGET.md表中仍写264KB并含较早3M模型阶段数据。它们是同SHA不同阶段的文档，不应混拼成一个精确当前预算；需要继续核对实际构建配置和板上日志。



Q10 5到6tok/s与63.3%能写成本批实测吗?

绝对不能。这是作者README在特定板上、特定模型与问题集的报告；本批只跑arena主机测试和预算算术，没有权重、语音识别、TTS、准确率评测或板上性能。规则代码处理时间等任务也是作者设计，不是本批模型能力。



可以用在哪里?

1. 给嵌入式多模型系统做分阶段工作集预算。
2. 在PC上编译真实分配器测试，先暴露重复占用和越界问题。
3. 把时间/计时器等确定性任务交给规则代码，不让小模型口算。
4. 审查同一固定提交中的README、预算文档和源码是否一致。

与旧知识的差异

复用量化、KV缓存、级联语音和证据优先笔记，增加阶段arena所有权、连续块预算及同SHA文档漂移案例，不新建整套同义内存概念。

不越过的证据边界

原帖已读，但所引用帖子实际讲Groki而非Ivy，已记录错链；通过项目官网和仓库核实Ivy。上游arena主机测试真实通过；未执行模型或ESP32语音。

完整来源见 sources.md；真实命令与首次失败见 experiment-log.md。代码压缩包包含复跑入口、受控输入和必要来源说明。

主实验 · 前半程

1. 声明测试范围

目的：记录真实上游C测试与教学预算的界限。

```
cd /workspace/reminder-batch-2026-11-11/item07/exercise
python3 lab.py 1
```

真实输出（关键字段）

{"python":"3.13.5","scope":"真实上游C arena测试 + 教学内存预算"}

验证：scope明确无模型/硬件。

2. 编译未改动arena与测试

目的：用gcc与官方主机日志桩编译；保留首次缺头文件失败及修复过程。

```
cd /workspace/reminder-batch-2026-11-11/item07/exercise
python3 lab.py 2
```

真实输出（关键字段）

{"compile_exit":0,"compiler":"gcc -std=c11 -Wall -Wextra","note":"完整gcc命令由lab.py打印，见日志；首次缺esp_log.h失败已保留。"}

验证：compile_exit=0，警告不隐瞒。

主实验 · 后半程

3. 运行官方test_arena

目的：检查所有权、对齐、溢出、rewind和复用。

```
cd /workspace/reminder-batch-2026-11-11/item07/exercise
python3 lab.py 3
```

真实输出（关键字段）

{"exit_code":0,"upstream_test":"test_arena OK","not_tested":["模型推理","ESP-IDF固件","麦克风","PSRAM时序"]}

验证：test_arena OK、exit_code=0；预期拒绝日志不是测试失败。

4. 计算阶段内存账本

目的：比较STT/LLM/TTS全部并驻与理想分时最大值。

```
cd /workspace/reminder-batch-2026-11-11/item07/exercise
python3 lab.py 4
```

真实输出（关键字段）

{"illustrative_MB":{"STT":5.4,"LLM":6.5,"TTS":2.5},"simultaneous_MB":14.4,"sequential_peak_MB":6.5,"arena_MB":7,"headroom_MB":0.5,"warning":"十进制教学近似；不含全部系统常驻内存，非ESP32测量"}

验证：14.4MB总和、6.5MB理想峰值、0.5MB示例余量，非板上实测。

来源与版本账本

原帖全文已读：https://x.com/i/status/2112109068584473072

引用：https://x.com/i/status/2111853756245737775

引用：https://x.com/i/status/2111732478486761627

iamankushpandit/esp_ai
SHA 35b2b77088a511a9fdaf3ee5f06ac7ed7bd069cc
https://github.com/iamankushpandit/esp_ai/tree/35b2b77088a511a9fdaf3ee5f06ac7ed7bd069cc

知识库查重 SHA

a8674777e18302b8804b137212b1396cbfe5a747

已读总览、接缝、级联语音、证据优先与Muse SDK笔记。样式沿用仓库青蓝卡片、大编号与橙色强调。

详细文件指纹、不可读URL及媒体未观看限制见 sources.md。作者性能不能写成本批实测；练习成功不能写成硬件已完成。

状态：待验证
原帖已读，但所引用帖子实际讲Groki而非Ivy，已记录错链；通过项目官网和仓库核实Ivy。上游arena主机测试真实通过；未执行模型或ESP32语音。