01 / 先辨证据，再动手

LEARN / OFFLINE LAB / 待验证

本地模型接入：接口兼容不等于无限额度

十个递进疑问 · 四步真实离线实验 · 增量候选

> **换算力路径不会消除成本、服务条款或平台限制。**

- 实读157字原帖、154字引用及下一层REA介绍。V100、模型强弱、47MB分析内存耗尽均是作者自述。
- 只研究Agent客户端→兼容API→模型服务的分层。本批不逆向Claude Code、不运行REA、不配置云relay。
- vLLM官方说明OpenAI兼容服务；本地HTTP模拟器返回MOCK ONLY，没有加载任何模型。

3–6项用途

- 用零依赖Mock先测客户端请求结构。
- 将网关响应与模型推理区分。
- 在部署前估算权重与KV缓存数量级。
- 为自有服务编写明确的请求上限测试。

02 / 由浅入深 · 疑问即目录

01 这里的三层架构是什么?

Agent组织任务，兼容API封装请求，模型服务消耗算力产生输出。中间relay只转运数据，不会让模型参数变小、token生成零成本。本次只在127.0.0.1做接口夹具，没有公网relay。[原帖/官方vLLM]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

02 “无限tokens”可靠吗?

只能当作者表达体验的说法。本地电力、显存、吞吐、上下文与并发都有上限，平台配额也不会被一个兼容接口合法消除。本文不教绕过条款，且无生产模型测试。[原帖批判]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

03 OpenAI兼容指哪些字段?

常见聊天请求含model、messages及生成参数，响应含choices中的message。兼容往往是子集，工具调用、流式片段、错误码和多模态仍可能不同。本次只测试非流式JSON最小形状。[官方/本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

04 Mock响应能证明模型会回答吗?

不能。夹具硬编码MOCK ONLY并标model=MOCK，HTTP200仅证明序列化、端口和回读可用，没有任何语义推理。这样可先排协议问题，再在获准环境单独测模型能力。[本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

05 为什么只绑定127.0.0.1?

回环地址使本次监听仅供同机测试，避免把未认证Mock暴露公网。但回环不等于对同机其他进程保密；代码没有凭据，仍不应用来承载私密业务。[本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

06 怎样做请求上限实验?

夹具自定max_tokens≤16，发送17返回真实HTTP400。它验证的是教学服务自己的拒绝分支，不证明vLLM有同样默认值。实际服务还需限体积、并发、时间和上下文窗口。[本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

07 INT4权重如何估算?

8B参数×0.5字节约40亿字节，是理想裸权重下限；量化尺度、未量化层、运行时缓存和临时张量另算。不能据此保证8GB显存可运行某个模型，本次没有模型加载。[本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

08 KV缓存为什么另算?

自回归模型要保留历史K/V，示例公式2×层数×KV头数×头维×token数×字节数。32层、8头、128维、4096token、FP16得到536870912字节。假设改变，结果也改变。[本实验]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

09 Pi与模型后端是同一个项目吗?

不是。Pi是Agent工具集合中的客户端/编排层，具体版本文档和自定义provider能力需要固定查看。本次固定pi-mono README，只确认项目入口，不安装、不改用户配置、不宣称任意模型即插即用。[固定README]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

10 REA逆向与本任务有什么边界?

引用帖描述了逆向工具与作者内存失败，但它不是实现本地模型接口的必要步骤。本批不分析专有代码、不复制功能、不复现配额绕行，只保留“证据不足不作结论”的研究纪律。[引用/边界]



依据标签说明：原帖/引用为作者自述；官方/源码为所列一手材料；本实验为真实运行的教学夹具。完整链接见末页与sources.md。

07 / 一个主实验 · 连续四步

步骤1 · 构造兼容请求形状

目的：先排最小JSON字段错误。

```
cd /workspace/chen-jiao-batch2-20261111/item04
python3 exercise/lab.py shape
```

真实结果（exit=0）：

```
{"model": "fixture-not-a-real-model", "messages": [{"role": "user", "content": "hello"}],
"max_tokens": 8}
request shape only; no inference
```

验证：明确fixture-not-a-real-model，不调用推理。

步骤2 · 回环兼容API模拟

目的：测试真实HTTP传输与JSON回读。

```
cd /workspace/chen-jiao-batch2-20261111/item04
python3 exercise/lab.py http
```

真实结果（exit=0）：

```
loopback actual HTTP 200 {'object': 'chat.completion', 'model': 'MOCK', 'choices':
[{'message': {'role': 'assistant', 'content': 'MOCK ONLY'}}]}
```

验证：200，model=MOCK，内容MOCK ONLY。

08 / 一个主实验 · 连续四步

步骤3 · 拒绝超预算请求

目的：验证自编服务的边界分支。

```
cd /workspace/chen-jiao-batch2-20261111/item04
python3 exercise/lab.py limit
```

真实结果（exit=0）：

```
actual HTTP rejection: 400 {"error": "fixture token cap"}
```

验证：max_tokens=17，夹具上限16，HTTP400。

步骤4 · 显存理论预算

目的：分开权重与KV缓存。

```
cd /workspace/chen-jiao-batch2-20261111/item04
python3 exercise/lab.py memory
```

真实结果（exit=0）：

```
hypothetical 8B INT4 raw weights= 4000000000 bytes; sample GQA KV= 536870912 bytes; overhead
excluded; no model loaded
```

验证：裸INT4约40亿字节，KV示例536870912字节；未加载模型。

诚实边界：无V100、未下载模型权重、未执行推理或Pi Agent安装。云relay、真实认证、多供应商兼容与性能未验证；不复现逆向和绕过额度。

09 / 版本、来源与待验证项

查重与新增

总览已有接缝与桩实现、能力层与后端路由、逐轮模型路由索引。本次只补接口契约、请求上限与权重/KV显存数量级，不重复路由框架。

补强接缝与桩实现：Mock必须在model及内容中明确标识，HTTP成功只证明协议路径；8B INT4与KV缓存公式是理论预算，不是可运行显存承诺。

固定基线

vault main a8674777e18302b8804b137212b1396cbfe5a747；读取 2026-11-11 01:28:04 北京时间（UTC+8）；官方网页按访问日与保存文件SHA256追溯，非不可变版本。其他项目Git SHA见sources.md。

实读来源

S1 https://x.com/i/status/2108940683428118896

S2 https://x.com/i/status/2108846931183378537

S3 https://x.com/i/status/2108844433940922843

S4 https://docs.vllm.ai/en/latest/serving/online_serving/

S5 https://github.com/badlogic/pi-mono/blob/b30d54b8aebe6408e02d1473446d25f8083da68f/packages/coding-agent/README.md

未验证与停止线

无V100、未下载模型权重、未执行推理或Pi Agent安装。云relay、真实认证、多供应商兼容与性能未验证；不复现逆向和绕过额度。

完整真实命令与输出：experiment-log.md；代码：exercise.zip。没有独立审核，不把作者数据当本次测量。所有成果只存隔离目录。