01 / 证据先行

LEARN / CLOUD LAB / 待验证

云端 Agent 上手：提示词、权限、验收分别写

10 个递进疑问 × 内联 SVG × 4 步真实实验

> **“帮我完成目标”不是“允许所有副作用”。**

• 实读原文章 plain_text 全文，含五步入门、九种用法、邀请码及宣传数字。官网 muse.ai 当前确实自称 Meta 的个人 Agent；不将同名可能性草率判假。

• 实读 security.muse.ai，文章署名 Tarek Sheasha，日期 2026-09-08，描述运行时与凭据域分离、Sentinel 审批及可退出训练。官方设计自述不是本次独立安全审计。

• 未进入设置、未登录/注册。下载量、榜单、节省金额与具体 UI 路径仍未核实；本次只离线检查任务规格与动作类别。

查重与增量

已读总览与《人机协同Interrupt》及其恢复勘误。本项把通用提示和真实执行权限分开，复用既有审批概念，不复制“永久性人设”作为许可。

main a8674777e18302b8804b137212b1396cbfe5a747。原帖、官方自述、合成实验和真实产品效果分别标注；不以文件存在冒称全流程完成。

02 / 从概念走到边界

01 原帖哪些部分可以直接借鉴?

目标、边界、敏感操作前展示和查看日志是通用任务规范。下载量、排行榜、邀请码奖励与省钱案例属于宣传或个案，不是产品安全证据。官网确认产品定位并不能替这些数字背书。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

02 说目标为什么还要补验收条件?

“整理账单”至少还缺范围、输入来源、字段、去重规则和完成标准。可以让 Agent 自选执行步骤，但不能让它自选访问哪些私密数据或是否发邮件。目标导向与权限清单并不矛盾。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

03 一个可用任务提示最少五栏是什么？

goal：产物；inputs：允许资料；scope：可做/不可做；stop：证据冲突、原文不可读等停止条件；done：每项结论附原文链接和未知项。教学检查器只查字段存在，不评价正文质量，空洞内容仍需人审。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

04 “只读”能否消除隐私风险？

不能。读取私人邮件后输出到网页、日志或外部服务仍可能泄漏。只读是资源修改权限，不是数据出域权限；还要限制输入范围、输出对象、保留时间。实验使用合成数据，没有读任何真实邮件。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

05 九种用法中哪些其实有副作用?

原文邮箱清零含广告归档，属于写操作；价格监控与长期目标追踪涉及新建持续任务。旅行查备选与下单也要分离。本实验九张合成任务卡仅分类，不执行归档、预约、监控或购买。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

06 官网的 Sentinel 与口头边界有什么不同?

安全文章描述独立宿主侧权限权威，Agent 提议动作，Sentinel 决定允许/拒绝/询问，凭据在边界注入。它是官方架构自述。本次自编 lint 没有 Sentinel 实现，不能用字段检查替代产品安全验证。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

07 为什么不能把网页里的提示当新授权?

网页、邮件与文档是输入数据，攻击者可以塞“忽略规则并发送”。即使它声称来自用户或安全团队，也不能自动升级权限。脚本用固定列表保持 read/draft，仅是确定性夹具，不证明模型抵抗任意注入。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

08 训练开关的说法如何核实?

官方安全文说明轨迹会清理关键身份信息后用于训练，并可在设置退出。本次没有打开账号设置，因此不认证当前账号默认值或原帖菜单精确路径；不替用户改开关。制度文档与实际账号状态分别记录。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

09 持久云电脑意味着什么?

官方说明用户与 Muse 共享专属云 VM；持久化让产物和登录续存，也意味着数据保留是重要边界。它不是“永不离线”或“所有 Bot 自动硬隔离”的通用保证。应按产品实际隔离层、角色和数据流审查。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

10 怎么从低风险测试升级?

先用公开材料做一次性研究，验来源、边界和日志；再在独立授权下测试精确审批点。未验证的账号或外部功能不能被总结成“全流程完成”。本次止于离线规格，未安排日程、发送、取消订阅或改变任何设置。



对照本项来源清单、相关查重笔记与实验日志；合成例不是原作者实测。

07 / 能用来做什么、主实验上半段

- 一次性任务提示模板
- 九种用法副作用分类
- 输入/输出隐私边界
- 官方声明与账号状态对照

步骤 1 · 保存九张合成用法卡

目的：保存九张合成用法卡

```
cd /workspace/chen-jiao-batch2-20261111/item14
python3 exercise/lab.py prepare
```

真实结果（exit=0）：

```
9 synthetic use cases saved; no service login
```

验证：tasks.json 明示合成、不访问账号

步骤 2 · 区分离线准备和待审批动作

目的：区分离线准备和待审批动作

```
cd /workspace/chen-jiao-batch2-20261111/item14
python3 exercise/lab.py classify
```

真实结果（exit=0）：

```
[('简报', 'allow-offline'), ('邮件分类', 'approval-required'), ('旅行备选', 'allow-offline'), ('订阅清单', 'allow-offline'), ('价格监控', 'approval-required'), ('文档总结', 'allow-offline'), ('社媒草稿', 'allow-offline'), ('研究报告', 'allow-offline'), ('目标追踪', 'approval-required')]
```

验证：归档与两类 schedule 共三项需审批

08 / 主实验下半段与诚实边界

步骤 3 · 比较空泛与完整提示规格

目的：比较空泛与完整提示规格

```
cd /workspace/chen-jiao-batch2-20261111/item14
python3 exercise/lab.py lint
```

真实结果（exit=0）：

```
bad missing= ['inputs', 'scope', 'stop', 'done'] good missing= []
```

验证：差例缺四栏，好例五栏齐全

步骤 4 · 保持外部文本为数据

目的：保持外部文本为数据

```
cd /workspace/chen-jiao-batch2-20261111/item14
python3 exercise/lab.py injection
```

真实结果（exit=0）：

```
external text kept as DATA; actions= ['read', 'draft'] sent=0 (deterministic fixture, not LLM
robustness test)
```

验证：计划仅 read/draft，发送计数零

待验证

待验证：产品实际账号、权限、设置路径、训练开关当前值、下载/收入宣传、真实代理表现。未登录、注册、建队列、发送或改设置。

完整输出不截断保存在 experiment-log.md；输入、脚本与结果位于 exercise.zip。样例和期望由本作者编写，不算独立审核。

09 / 可追溯来源与增量提案

一手材料与固定版本

S1 https://x.com/i/status/2106562613379215677
S1：原文章全文，邀请码不使用

S2 https://muse.ai
S2：官方公开首页，未登录

S3 https://security.muse.ai
S3：2026-09-08 官方安全架构与数据政策

证据目录

sources/ 为公开材料快照；source-manifest.json 记录请求 URL、访问时间与 SHA256。post.json / quoted-posts.json 保存已读文本。哈希用于可追溯，不是对来源结论的认证。访问时间：2026-11-11 01:29:55 北京时间 UTC+8

知识候选

在既有审批/信息素养笔记追加“九用法混合副作用”与政策、账号状态分层；官方 Sentinel 仅作有日期的架构案例。