

Qwen Image 2.1 小白学习指南

看懂统一图像模型 亲手验证提示词输出接口

学完能做什么

解释模型的四个主要组件；区分官方能力与实测证据；亲手让官方接口代码处理正常答复、坏 JSON 和越界字段。

历史实测：2026-10-05 07:05 UTC / pe_core.py

没有下载模型权重，没有模型 / API 推理，没有生成图片

12 个问题就是阅读路线

- | | |
|-----------------------------------|-------------------------|
| 01 它把哪几种图像任务放到了一起 | 07 VAE 为什么能让图像在小空间里处理 |
| 02 一张图从输入到输出会经过谁 | 08 原生 RGBA 输出为什么仍要验收 |
| 03 7B 为什么不等于整套模型的大小 | 09 多参考图和局部编辑最容易弄错什么 |
| 04 单流 DiT 的单流具体指什么 | 10 前缀 KV 缓存到底省掉了什么 |
| 05 为什么文本和图像使用不同粒度的注意力 | 11 提示词改写器和图像模型是什么关系 |
| 06 Flow Matching 和 Euler 调度器分别做什么 | 12 parse_ok 为真就能放心交给下游吗 |

证据分层

官方声明 → 固定版本源码 / 配置核对 → 本地接口实测

图像质量、透明效果、显存、推理耗时仍未验证。图中素材均为手工概念 SVG。

许可边界

代码和模型适用 Qwen Research License。此练习用于研究与评估；商业用途须另行核对并取得所需许可。练习包保留官方许可全文；本指南不构成法律意见。


01

它把哪几种图像任务放到了一起

同一图像模型承接生成和编辑，输入条件决定任务。

文本生图是给出文字后生成图像；图像编辑是在已有图像条件上按文字修改。官方还声明支持透明图像、主体提取与多参考图编辑。把它想成同一间设计工作室：有时从白纸开始，有时带着草图来修改。具体入口是 QwenImage21Pipeline，能接收 prompt 和可选的 image。

例子：先用文字描述一把蓝色茶壶，再在授权自有照片上把茶壶背景改为浅色。这里是用途说明，本次没有生成图片。



官方能力示意，本图是手工 SVG，不是模型输出

依据 S1


02

一张图从输入到输出会经过谁

编码器理解条件，DiT 更新潜变量，VAE 解码成图。

管线是把多个组件按顺序连接起来的程序。文本编码器把文字和参考图变成条件表示；DiT 是用 Transformer 结构处理图像潜变量的生成模块；调度器决定每次更新的时间步；VAE 把紧凑的潜变量还原成像素。提示词改写器是可选的前置组件，不能和图像模型混为一谈。

类比：需求翻译员、绘图员和出图设备各有分工。真正的对象分别是条件表示、潜变量与最终像素。



主生成链路；可选提示词改写发生在此链路之前

依据 S1、S3


03

7B 为什么不等于整套模型的大小

7B 指视觉生成组件，另有 8B 文本编码器与 VAE。

B 表示十亿参数。官方的 7B 对应 32 层视觉 Transformer；架构说明另列 Qwen3-VL 8B 文本编码器。磁盘文件还受精度、分片和其他组件影响。已读取的权重元数据合计约 30.841 GiB，不能拿“7B”直接换算整套下载量，更不能当显存需求。

本环境没有可用 GPU，实测可用磁盘约 29.19 GiB。权重元数据已经超过余量，因此选择不下载权重，只运行接口纯函数。没有测量推理显存或速度。



参数归属示意；文件体积、内存占用与显存需求不是同一量

依据 S1、S3

04

单流 DiT 的单流具体指什么

条件序列与生成图像序列进入统一的注意力计算结构。

单流是架构组织方式，不是“只处理一种输入”。在这一模型中，文本和图像块可以参与同一个生成网络。注意力负责决定序列元素之间如何交换信息；实际允许哪些元素互相看见，仍受掩码控制。官方配置显示 num_layers 为 32，不能据此推断任何设备上的生成速度。

可以把不同输入看作进入同一教室的几组学生；单流描述教室组织，掩码描述谁能向谁提问。



概念图省略具体张量形状，不代表完整计算图

依据 S1、S3


05

为什么文本和图像使用不同粒度的注意力

文本按 token 因果约束，图像按块允许内部双向交流。

因果掩码限制当前位置读取未来位置；双向注意力允许同一组位置相互访问。官方称此为混合粒度注意力，并给出块因果条件：位置满足因果关系，或属于同一图像块时可见。这样既保留条件顺序，又让一张图内部的信息能共同参与计算。

文本像按顺序展开的句子；同一图像块更像一张同时可见的工作台。这个比喻解释信息可见性，不是实际计算实现。



掩码是可见性规则，不是把像素涂黑的编辑蒙版

依据 S1


06

Flow Matching 和 Euler 调度器分别做什么

前者描述学习的连续变化方向，后者把变化拆成离散步。

Flow Matching 让模型学习从初始噪声走向数据的变化场；Euler 方法用当前估计方向推进一小步。这里的调度器为 FlowMatchEulerDiscreteScheduler，并启用动态 shifting。官方示例使用 40 个推理步；它只是示例配置，本次没有验证减少或增加步数对画质、耗时的影响。

可以把潜变量从噪声逐步更新理解成沿一张方向图走路。每一步不是保存一张成品图，而是推进内部表示。



路线是教学示意，不是一次真实推理轨迹

依据 S1、S3


07

VAE 为什么能让图像在小空间里处理

它在压缩后的潜空间和像素空间之间转换。

VAE 是变分自编码器。该模型配置中的空间缩放倍数为 16，潜变量通道数为 64，输入与输出为 4 通道。直观上， 2048×2048 的空间网格可对应 128×128 的压缩网格，但还必须带上通道数与管线的打包方式，不能仅靠面积比估算全部内存。

类比压缩草稿：草稿的格子更少，每个格子携带多维信息；解码器负责把它展开成像素。



尺寸只用于解释空间缩放；不是运行时完整张量或显存估算

依据 S1、S3


08

原生 RGBA 输出为什么仍要验收

透明度必须来自 alpha 通道，棋盘格只是显示方式。

沿用已有透明通道知识：RGBA 在红绿蓝之外加上 alpha。模型特有的新点是四通道 VAE，而提示词改写器的 load_image 静态实现会把输入转为 RGB；这两个路径不能混为一谈。官方声明该模型支持原生透明生成和编辑；验收时仍要查看文件模式、alpha 分布以及叠加后的边缘。仅看起来像棋盘格，不能证明图片透明。

例子：把茶壶贴纸分别叠在深色和浅色背景上，检查边缘是否有白边。本次没有生成或验收任何 alpha 图像。



透明度概念示意；这不是透明图像生成实验

依据 S1、S2、S3


09

多参考图和局部编辑最容易弄错什么

先固定参考图顺序，再说明改哪里、保留什么。

官方声明最多支持 10 张参考图，并支持圈选、涂画或独立蒙版等局部编辑指示。提示词接口的 `build_messages` 会先放图像，再放文本，图像顺序对应 `<image1>`、`<image2>` 等引用。顺序错了，句子可能通顺但指向了错误对象。不要把每种编辑提示格式都当成完全等价的 API。

例子：图 1 是授权使用的杯子，图 2 是背景纹理；明确“保持图 1 杯型，使用图 2 的配色”。本次用合成字符串占位标记验证顺序，不加载真实图片。



最多 10 图是官方能力上限声明，本次未做多图质量测试

依据 S1、S2


10

前缀 KV 缓存到底省掉了什么

重复利用不变条件的中间结果，避免每步都重算同一前缀。

KV 是注意力计算中的 Key 和 Value。文本与条件图像作为相对固定的前缀，在首个去噪步骤计算后可缓存，在后续步骤复用。官方把这与 `causal_condition` 配置联系起来。缓存通常需要额外保存中间数据；能节省多少时间，取决于输入、实现和设备，不能从机制说明推出本机加速倍数。

像在一系列迭代中保留已经读好的题目，只重新处理正在修改的答案。这里复用的是张量，不是把旧图片直接当新图片。



缓存机制来自官方说明；本次不报告加速或显存实测

依据 S1、S3


11

提示词改写器和图像模型是什么关系

改写器生成结构化文字，图像管线才负责生成像素。

官方提供独立的 T2I 和 I2I 提示词改写检查点，基于微调的 Qwen3.5-VL 9B。T2I 表示文生图，edit 表示编辑模式；它们有各自的系统提示和采样配置。pe_core.py 共享输入组织、答复解析和记录输出。这里的练习只运行这些纯函数，合成答复由练习脚本构造，绝不是改写模型生成的内容。

先看接口契约：文生图答复包含 rewritten_prompt 和 wh_ratio；编辑还可能包含 ratio_follow，让输出继承某张参考图的比例。



主实验只覆盖消息组织与 JSON 解析，不覆盖两种模型推理

依据 S1、S2


12

parse_ok 为真就能放心交给下游吗

不够。能解析、字段合规、任务成功是三个不同层次。

parse_answer 从答复尾部向前寻找 JSON 对象，只要找到非空的 rewritten_prompt 字符串，就能返回 parse_ok=true。它还兼容拼写 rewritten_prompt，并把部分字段转成字符串。它没有完整检查比例是否在允许列表、引用是否存在。解析失败时保存原答复作为回退，parse_ok=false；因此必须检查这个标志。

练习会故意加入可解析但比例或引用不合规的样本，再用独立校验规则分开统计。别把这些人工样本通过率说成模型质量分数。



本次实测边界：解析层 + 自建接口校验；未验证生成质量

依据 S2

这个项目给我什么

以下为官方能力与可研究用途，未做生成效果验收

1 文字生成图像

官方统一管线接受自然语言 prompt；分辨率、比例和参数仍需按入口确认。

产品练习图

用自有商品图研究换背景、保留杯型或茶壶轮廓的指令写法。

2 参考图条件编辑

官方说明涵盖单图及多参考图组合，最多 10 张参考图。

教学插图

把课程概念改写成可画的场景，人工复核知识与文字准确性。

3 局部区域编辑

官方说明支持圈选、涂画或独立蒙版指示；不同入口的实际格式需逐项核对。

透明贴纸素材

研究 RGBA 资产进入课件或界面的流程，逐张检查边缘和透明度。

4 原生 RGBA 与主体提取

官方说明支持透明生成、透明层编辑及主体提取；输出仍需 alpha 验收。

多参考构图

用已获授权的物件参考研究元素组合，并记录每张图的角色和顺序。

5 提示词改写辅助链路

独立改写模型输出结构化提示词和比例信息；纯函数可单独进行接口测试。

生成系统接口测试

先在 CPU 上验证 JSON 契约、错误回退和日志，再考虑昂贵推理。

最适合现在动手的，是接口验证

不具备推理硬件时，仍能先学会固定版本、读取官方实现、构造最小反例，以及把解析成功和业务有效分开。后来接入模型时，这些验收步骤仍可复用。

进一步做图像实验前

重新核对运行框架版本、完整磁盘余量、可用加速硬件、许可与输入素材授权，再设计质量和 alpha 验收。不能拿本次毫秒级脚本耗时估算图片生成速度。

在 CPU 上亲手检验输出契约

原实验于 2026-10-05 07:05 UTC 从全新解压目录执行；公开整理未重跑。复现使用 Python 3.10+ 标准库，在 exercise 目录执行；无需联网、GPU、API 密钥或权重。

01 核验环境与固定代码

```
python3 -I -S -B check_environment.py
```

目的：确认 Python 至少为 3.10，隔离启动和两个固定文件哈希。

实际结果：Python 3.12.14；pe_core.py 和 LICENSE 均 SHA256 OK。

成功判据：最后一行含 READY；命令退出码为 0。

实测 UTC 07:05:04.615 → 07:05:04.650；0.035 秒；退出码 0

02 真正运行官方纯函数

```
python3 -I -S -B experiment/verify_contract.py > results.json
```

目的：构造普通物体的合成输入，运行消息、解析与记录测试。

实际结果：写出 results.json；上游预期行为检查 21/21 通过。

成功判据：退出码 0；步骤 4 会显示 21/21，JSON 含逐例证据。

实测 UTC 07:05:04.651 → 07:05:04.722；0.072 秒；退出码 0

03 看见参考图顺序

```
python3 -I -S -B inspect_results.py messages
```

目的：从本次结果读取消息内容，核对引用的先后顺序。

实际结果：依次为 image1 标记、image2 标记、文本。

成功判据：输出 ORDER PASS；标记没有被请求或解码。

实测 UTC 07:05:04.722 → 07:05:04.751；0.029 秒；退出码 0

让坏样本暴露接口边界

合成答复只用于可重复的程序实验，统计结果不是模型成功率。

04 比较能解析与不能解析

```
python3 -I -S -B inspect_results.py parser
```

目的：观察正常、兼容、末尾候选和坏 JSON 的真实结果。

实际结果：正常 JSON、旧键与末尾有效候选能提取；无 JSON、截断、尾逗号、空提示词回退为 False。

成功判据：共 21/21 预期行为检查通过；json_repair absent。

实测 UTC 07:05:04.751 → 07:05:04.788；0.036 秒；退出码 0

05 给下游加一道自定检查

```
python3 -I -S -B inspect_results.py validate
```

目的：用独立编写的消费者策略，检查比例选项、编辑选择互斥与两张参考图范围；它不是官方 schema。

实际结果：上游可解析的 6 例中，本练习策略接受 2 例，拒绝 4 例；四例分别涉及双字段、未知比例、缺选择和越界引用。

成功判据：输出 LOCAL POLICY CHECKS: 6/6 matched; 2 ACCEPT; 4 REJECT。

实测 UTC 07:05:04.788 → 07:05:04.811；0.023 秒；退出码 0

该记住的实验结论

21/21 证明行为符合测试预期，包含宽松解析边界；自建策略的 6/6 证明本练习规则工作。两者都没有证明模型出图质量。

把新知识接到已有知识上

已有的提示词约束、输出契约、透明通道真假判定和证据分层不重复新建。本次新增重点是单流 DiT、混合粒度注意力、前缀 KV 复用、RGBA VAE，以及 pe_core 解析与字段校验之间的边界。详见配套知识笔记。

实际查重范围

本次学习时检索了固定公开索引的 394 条元数据，实际读取 19 篇相关公开正文；其余 375 篇未做全文阅读。相关知识来源与指纹见配套笔记。这个范围说明不代表已通读整个知识库。

固定版本与原始依据

S1 官方 GitHub 说明与架构

S2 官方提示词接口源码 pe_core.py

S3 模型卡和组件配置

S4 Qwen Research License Agreement

GitHub commit 6627d87c6433151463ec4b48b8945a24fcf16a35

Hugging Face revision d26bb61231c349cf6b7896fa83353113880e1ba3

许可区分：本练习随附的 Qwen 代码与模型适用 Qwen Research；Diffusers 的 Apache 2.0 许可不能替代它。点击上方 S4 查看固定版本许可。

证据与可复现材料

配套练习 ZIP 内含未改动的官方 pe_core.py、许可证、来源与 SHA-256、合成用例和独立字段校验器。实验日志记录精确命令、UTC 时间、退出码及关键输出；知识笔记记录新旧概念关联与查重依据。

下一步怎么判断进步

先能解释为什么 parse_ok=true 仍须字段校验，再能独立复现五步实验。未来取得合适硬件和必要许可后，另建图像质量、alpha 和资源用量基线；本次不提前填入这些未测结果。